DETECÇÃO DE ANOMALIAS EM NAVES ESPACIAIS: AVALIAÇÃO DA CONFIABILIDADE DE ALERTAS EM DADOS DE TELEMETRIA

José João Monteiro Costa[1], Maria Eduarda de Lima[1], Elliot Briant[2].

[1]Grupo de pesquisa em Estatística, Ciência de dados e IA, Instituto Geração de Marte, Brasil
[2]Orientador do grupo de pesquisa em Estatística, Ciência de dados e IA, Instituto Geração de Marte, Brasil.

Resumo: A telemetria de uma espaçonave registra, ao longo do tempo, o comportamento de seus subsistemas, e a detecção de anomalias nesses dados faz parte da operação. Detectores automáticos, porém, também emitem alertas para eventos esperados, como manobras e ajustes planejados, que são anotados como eventos raros nominais. Esses alertas aumentam o trabalho de verificação das equipes e reduzem a confiança no detector. Este trabalho investigou como características da telemetria e informações operacionais podem contribuir para avaliar e interpretar alertas de anomalias para garantir sua confiabilidade. Foram utilizados dados da Agência Espacial Europeia (ESA) disponibilizados no *European Space Agency Anomaly Detection Benchmark* (ESA-ADB). A metodologia seguiu em duas etapas: a análise exploratória e descritiva dos eventos, dos desvios estatísticos dos sensores e dos telecomandos; e o desenvolvimento de um protótipo de assistente baseado no *Model Context Protocol* (MCP), destinado a consultar ferramentas e reunir evidências para apoiar a interpretação dos alertas. A análise sugeriu que o valor do sensor, isolado, não separa de forma consistente anomalias e eventos raros, e que informações de contexto operacional, como os telecomandos, podem contribuir para essa separação. O trabalho propõe, assim, uma forma de apoiar no monitoramento e análise de dados de telemetria.

Palavras-chave: detecção de anomalias, telemetria, alertas, Inteligência Artificial, MCP.

Abstract: Spacecraft telemetry records the behavior of onboard subsystems over time, and anomaly detection in these data is an important part of spacecraft operations. However, automated detectors may also generate alerts for expected events, such as planned maneuvers and adjustments, which are labeled as nominal rare events. These alerts increase the verification workload of operational teams and reduce confidence in the detector. This study investigated how telemetry characteristics and operational information can contribute to evaluating and interpreting anomaly alerts to ensure their reliability. Data from the European Space Agency (ESA), available through the *European Space Agency Anomaly Detection Benchmark* (ESA-ADB), were used. The methodology consisted of two stages: an exploratory and descriptive analysis of annotated events, statistical deviations in sensor readings, and telecommands; and the development of an assistant prototype based on the *Model Context Protocol* (MCP), designed to access tools and gather evidence to support alert interpretation. The analysis suggested that sensor readings alone cannot consistently distinguish anomalies from nominal rare events, and that operational context information, such as telecommands, may contribute to this distinction. Thus, this study proposes an approach to support the monitoring and analysis of spacecraft telemetry data.

Keywords: anomaly detection, telemetry, alerts, Artificial Intelligence, MCP.

1. Introdução

Uma nave espacial pode estar a milhões de quilômetros da Terra, mas seu funcionamento precisa ser acompanhado mesmo à distância. Para isso, utiliza-se a telemetria, um conjunto de dados enviados pela nave que permite monitorar seus sistemas ao longo do tempo. Essas informações incluem medidas como temperatura, tensão elétrica e níveis de energia. Como uma missão pode gerar milhões de registros, analisar manualmente todos esses dados se torna uma tarefa difícil. Por isso, são utilizados métodos automáticos para identificar comportamentos fora do padrão e ajudar as equipes a reconhecer situações que precisam de atenção [1, 2].

Entretanto, nem todo comportamento incomum representa uma falha. Manobras, ajustes e outras operações planejadas também podem alterar os valores dos sensores, mesmo quando a nave está funcionando

corretamente. Assim, um detector pode emitir alertas tanto para anomalias quanto para eventos esperados, chamados de eventos raros nominais. Isso dificulta a interpretação dos resultados e pode aumentar o trabalho das equipes responsáveis pelo monitoramento. Portanto, identificar um desvio nos dados não é suficiente: também é importante compreender o contexto em que ele ocorreu [1, 2].

Diferentes técnicas são utilizadas para detectar anomalias, desde limites estatísticos até modelos de aprendizado de máquina. Embora esses métodos possam reconhecer padrões incomuns, seu desempenho depende das características dos dados e dos critérios utilizados na avaliação. Além disso, informações como o comportamento de outros sensores, o histórico de eventos e os telecomandos enviados à nave podem ajudar a interpretar os alertas. Os telecomandos são instruções executadas pela espaçonave e podem estar próximos de mudanças esperadas em seu funcionamento, embora essa proximidade não comprove uma relação de causa e efeito [5, 6, 9, 10].

Outro desafio consiste em transformar um alerta em informação útil para quem precisa investigá-lo. Saber que determinado canal apresentou um comportamento incomum não explica, por si só, o que pode ter acontecido. Informações complementares, como o comportamento de outros canais, a qualidade dos dados, o histórico de eventos semelhantes e os comandos enviados à nave espacial, podem ajudar a contextualizar a ocorrência. Ainda assim, a proximidade temporal entre um comando e uma anomalia não comprova que um tenha causado o outro. Nesse cenário, abordagens voltadas à explicabilidade procuram tornar as evidências e as limitações de uma detecção mais compreensíveis, contribuindo para que os alertas sejam analisados de maneira criteriosa e de forma ágil [1, 9, 10].

Diante desse cenário, este trabalho investiga como características da telemetria e informações do contexto operacional podem contribuir para a interpretação de alertas de anomalia. Para isso, são analisados dados de duas missões do *European Space Agency Anomaly Detection Benchmark* (ESA-ADB), considerando a duração e a distribuição dos eventos, os desvios nos valores dos sensores e a proximidade temporal com telecomandos [2, 11]. Também é apresentado um protótipo de assistente baseado em inteligência artificial, que utiliza o *Model Context Protocol* (MCP) para consultar e organizar evidências. O objetivo do assistente não é detectar falhas automaticamente, mas apoiar o monitoramento e a análise humana, oferecendo informações que ajudem a compreender os alertas de forma ágil.

2. Metodologia

A pesquisa foi desenvolvida em duas etapas: uma análise exploratória de dados de telemetria, buscando características que ajudem a interpretar anomalias e eventos raros, e o desenvolvimento de um protótipo de assistente de inteligência artificial para reunir e apresentar evidências sobre os alertas.

2.1. Conjunto de Dados e Estrutura das Informações

Foi utilizado o *European Space Agency Anomaly Detection Benchmark* (ESA-ADB), um conjunto de dados público desenvolvido para apoiar pesquisas sobre detecção de anomalias em telemetria de satélites [2, 11]. Ele reúne dados de duas missões espaciais, denominadas Missão 1 e Missão 2, incluindo registros de telemetria, anotações de eventos e informações sobre a execução de telecomandos.

A telemetria é organizada em canais que registram valores ao longo do tempo. Cada registro está associado a uma marca temporal (timestamp), permitindo observar como os valores de um canal variam durante a missão. As anotações de eventos, por sua vez, descrevem ocorrências identificadas no conjunto de dados, incluindo seus intervalos temporais e suas classificações. Já os registros de telecomandos contêm informações sobre comandos executados e seus respectivos horários, possibilitando investigar se determinadas ocorrências aconteceram próximas a essas execuções.

Esses componentes fornecem perspectivas complementares sobre o comportamento do sistema: os canais mostram o que foi registrado, as anotações indicam quais intervalos foram identificados como eventos e os

telecomandos oferecem informações sobre o contexto operacional. A presença dessas informações permite investigar possíveis associações entre diferentes registros, mas não comprova, por si só, uma relação causal entre comandos e eventos.

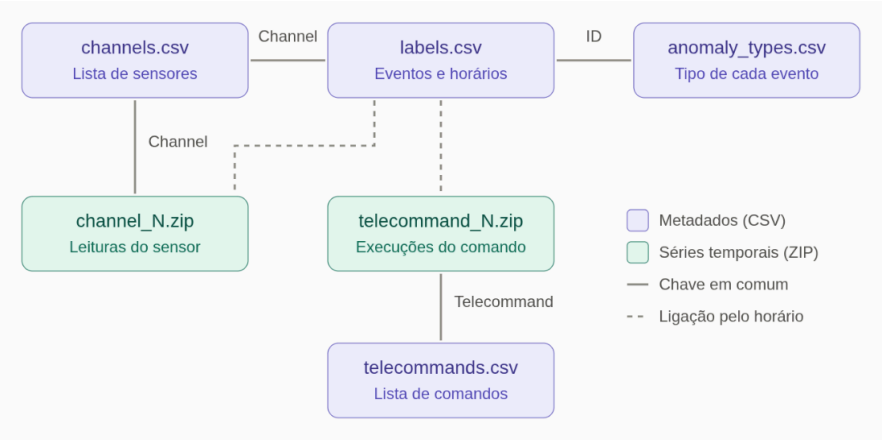


Figura 1: Diagrama da estrutura de dados ESA-ADB

Os nomes dos canais e dos telecomandos são anonimizados no conjunto utilizado. Dessa forma, os identificadores permitem distinguir registros, mas não revelam necessariamente qual variável física está sendo medida ou qual ação corresponde a cada comando.

Para este estudo, foram selecionados subconjuntos de canais de cada missão. Na Missão 1, foram analisados os canais 41 a 46, totalizando seis canais. Na Missão 2, foram selecionados os canais 18 a 28, totalizando onze canais. A escolha delimita o escopo da investigação: os resultados apresentados dizem respeito aos canais e eventos considerados, não à totalidade dos dados das missões.

Tabela 1. Resumo dos dados da Missão 1 e 2

Parâmetro Avaliado	Missão 1 (Canais 41–46)	Missão 2 (Canais 18–28)
Período	14 anos (2000 a 2013)	3,5 anos (2000 a 2003)
Leituras por Canal	15.381.169	7.387.262 registros
Total de Eventos Únicos Catalogados	118 eventos	622 eventos
Distribuição das Classes Anotadas	63 Raros / 51 Anomalias / 4 Gaps	603 Raros / 19 Anomalias / 0 Gaps

2.2. Preparação dos Dados e Análise Exploratória

Inicialmente, verificou-se a qualidade dos dados, considerando valores ausentes, infinitos e horários duplicados, sem identificar esses problemas nos recortes selecionados. Em seguida, os eventos foram comparados por categoria, duração, distribuição temporal e quantidade de canais associados. A duração foi estimada pela diferença entre o primeiro início e o último término anotado para cada evento, podendo não representar exatamente o tempo de ocorrência do fenômeno.

Para analisar os desvios dos sensores, foram utilizadas a mediana e o desvio absoluto mediano (MAD), uma medida de variação menos sensível a valores extremos. Foi adotado um limiar exploratório de três unidades

de variação típica, com o objetivo de observar como esse critério se comportava em períodos normais, anomalias e eventos raros, sem considerá-lo um detector definitivo.

Também foi investigada a presença de telecomandos nas janelas de uma e seis horas anteriores aos eventos. Parte dos resultados foi comparada com janelas selecionadas aleatoriamente, buscando identificar possíveis associações temporais. Essa análise não permite afirmar que os comandos tenham causado as alterações observadas.

2.3. Desenvolvimento do protótipo de assistente baseado em MCP

O *Model Context Protocol* (MCP) padroniza a comunicação entre aplicações de inteligência artificial e ferramentas ou fontes externas (como APIs ou banco de dados, por exemplo). Neste trabalho, foi utilizado para conectar um assistente baseado em modelo de linguagem a ferramentas de consulta do ESA-ADB. Assim, o assistente pode recuperar informações sobre telemetria, eventos anteriores e telecomandos, sem atuar como um detector de anomalias ou confirmar automaticamente a existência de falhas.

O protótipo disponibiliza ferramentas (*tools*) para consultar estatísticas de janelas temporais, verificar a qualidade dos dados, buscar eventos semelhantes, recuperar o histórico de alertas e consolidar evidências relacionadas a uma ocorrência. A partir das informações retornadas por essas ferramentas, o modelo de linguagem pode elaborar uma resposta em linguagem natural, organizando os dados relevantes para apoiar a análise.



Figura 2: Arquitetura do protótipo de assistente baseado em MCP

3. Resultados e Discussão

3.1. Caracterização dos Eventos nas Missões

A análise dos subconjuntos selecionados do ESA-ADB revelou diferenças na quantidade e na composição dos eventos anotados nas duas missões. Na Missão 1, foram identificados 118 eventos associados aos canais 41 a 46: 51 anomalias, 63 eventos raros e quatro lacunas de comunicação. Na Missão 2, o recorte dos canais 18 a 28 reuniu 622 eventos, dos quais 19 foram classificados como anomalias e 603 como eventos raros.

A duração e a quantidade de canais associados também variaram. Na Missão 1, 29 das 51 anomalias duraram menos de um minuto, enquanto os eventos raros tiveram duração mediana de aproximadamente uma hora e meia. Além disso, 113 dos 118 eventos apareceram nos seis canais selecionados. Na Missão 2, as durações medianas foram próximas entre anomalias e eventos raros, cerca de uma hora e 46 minutos, respectivamente. Entretanto, 16 das 19 anomalias foram anotadas em até três canais, contra aproximadamente 15% dos eventos raros. Esses resultados sugerem que duração e quantidade de canais podem ajudar a caracterizar as ocorrências, mas não permitem diferenciá-las de forma consistente nas duas missões. A presença de

anomalias muito curtas na Missão 1, por exemplo, indica que uma regra que priorize apenas eventos prolongados poderia deixar de considerar parte das ocorrências anotadas como anomalias.

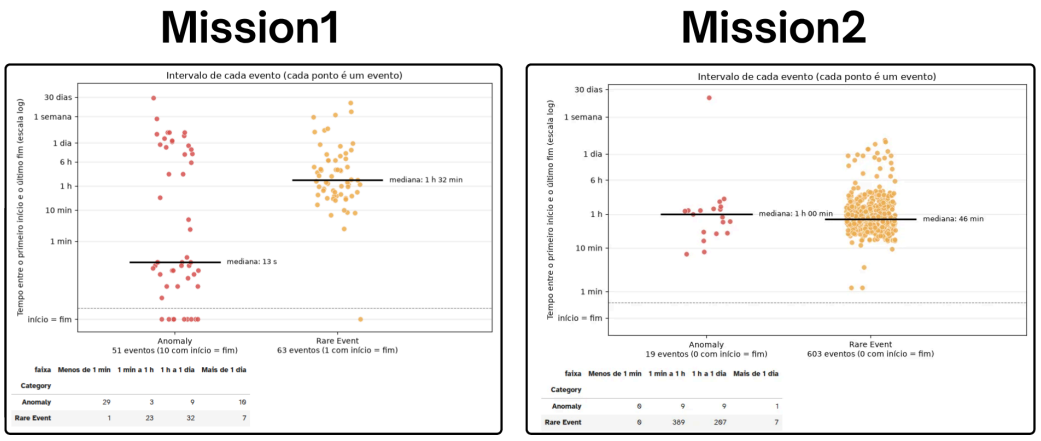


Figura 3: Distribuição da duração dos eventos por categoria nas Missões 1 e 2

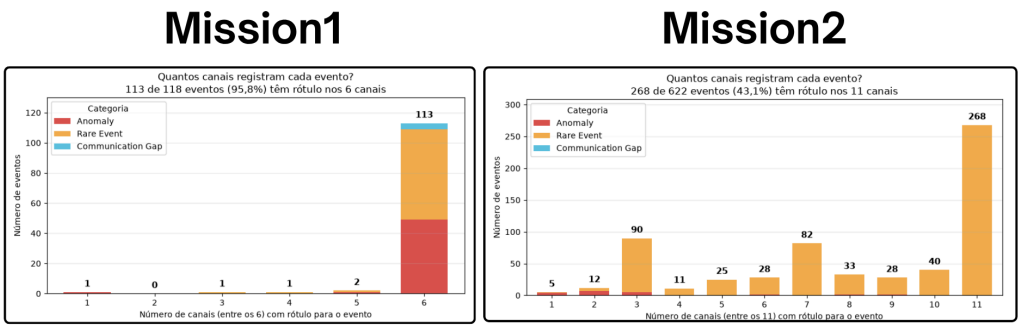


Figura 4: Distribuição dos eventos conforme a quantidade de canais associados nos subconjuntos das Missões 1 e 2

3.2. **Desvios dos sensores em relação ao comportamento habitual**

A análise baseada na mediana e no desvio absoluto mediano (MAD) mostrou que valores muito diferentes do habitual nem sempre correspondem a anomalias. Na Missão 1, aproximadamente 96% dos segmentos normais do canal 41 ficaram abaixo do limiar exploratório de três unidades de variação. As anomalias apresentaram desvios maiores, com mediana próxima de 26 unidades. Entretanto, cerca de um quinto delas ficou abaixo do limiar, enquanto aproximadamente um terço dos eventos raros o ultrapassou.

Na Missão 2, o canal 18 apresentou um comportamento diferente. Como seus valores habituais variavam muito pouco, aproximadamente metade dos segmentos normais ultrapassou o mesmo limiar. Além disso, os eventos raros apresentaram desvios medianos maiores que as anomalias, aproximadamente 237 contra 40 unidades. Isso indica que um desvio elevado pode representar tanto uma anomalia quanto uma mudança esperada no funcionamento da nave. Portanto, o valor isolado do sensor não é suficiente para interpretar um alerta com segurança.

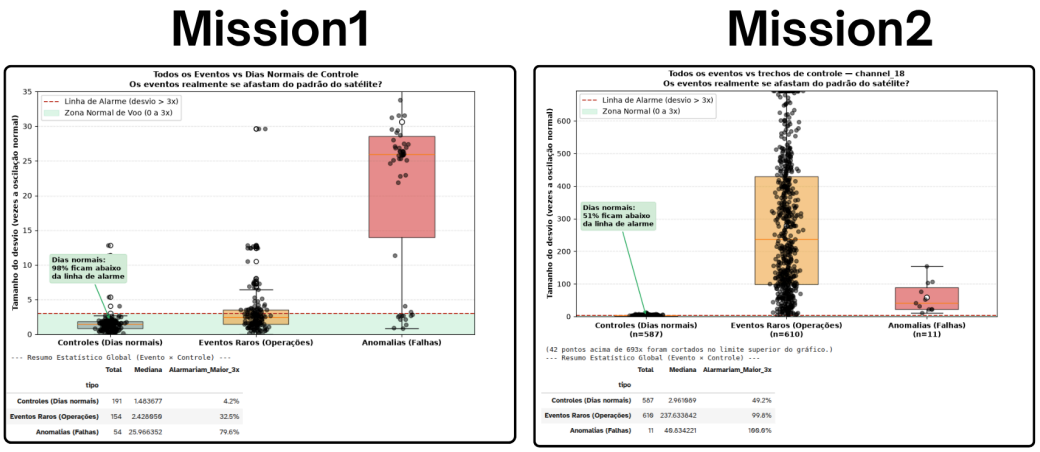


Figura 5: Desvios em relação ao comportamento de referência nos canais 41 da Missão 1 e 18 da Missão 2

3.3. **Proximidade Temporal entre Telecomandos e Eventos**

A análise dos telecomandos buscou investigar se determinadas execuções estavam temporalmente próximas aos eventos anotados. Na Missão 1, o telecomando identificado pelo código 38 apareceu nas seis horas anteriores a aproximadamente 44% dos eventos raros analisados, enquanto não foi observada essa proximidade para as anomalias consideradas nessa comparação.

Em uma janela mais curta, de uma hora, aproximadamente 98% dos eventos raros apresentaram algum telecomando executado anteriormente. Nas janelas selecionadas aleatoriamente para comparação, essa proporção foi de cerca de 30%. A diferença sugere uma associação temporal que merece investigação, mas não permite concluir que o telecomando tenha provocado os eventos raros.

Além disso, o comportamento não foi uniforme entre as missões. Na Missão 2, também foram observados casos de anomalias próximas temporalmente a telecomandos. Isso indica que a proximidade temporal, isoladamente, não é suficiente para diferenciar as categorias de eventos de forma consistente.

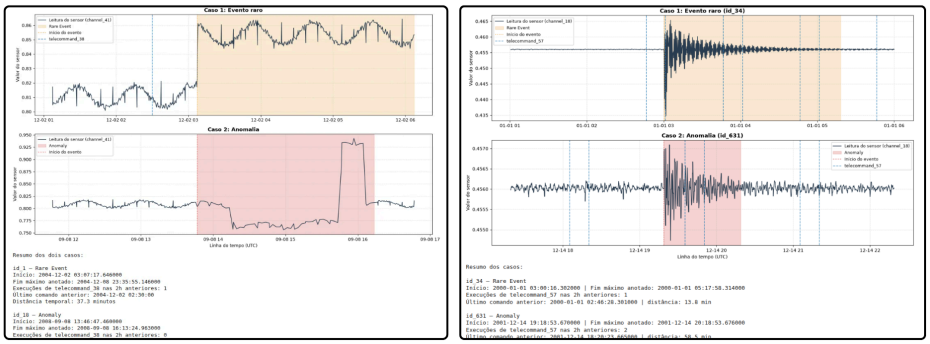


Figura 6: Séries Temporais de eventos com telecomandos executados em janelas temporais anteriores às ocorrências.

A associação temporal observada pode ajudar a direcionar uma investigação, mas não estabelece causalidade. Para avaliar se um telecomando está relacionado a determinado evento, seria necessário considerar também o significado operacional do comando, o comportamento dos canais envolvidos e outras informações contextuais que não estão necessariamente disponíveis no conjunto de dados anonimizado.

3.6. **Protótipo MCP: Exemplos de Funcionamento e Limitações**

O protótipo foi utilizado em testes exploratórios com o GitHub Copilot, na versão gratuita disponível no Visual Studio Code. Por meio das ferramentas MCP, o assistente consultou dados históricos, reuniu evidências e apresentou explicações em linguagem natural.

Ferramentas disponibilizadas pelo protótipo MCP:

- tool_analyze_window: Calcular estatísticas de uma janela temporal.
- tool_check_data_quality: Verificar a qualidade dos dados.
- tool_find_similar_events: Consultar eventos históricos semelhantes.
- tool_alert_track_record: Consultar o histórico de alertas.
- tool_explain_alert: Consolidar evidências relacionadas a um alerta.
- tool_shift_summary: Produzir um resumo consolidado para a passagem de turno.

Em uma das consultas, foram encontrados 138 eventos históricos associados ao canal 22, dos quais 135 eram eventos raros e três eram anomalias. Em outro exemplo, o assistente identificou uma inconsistência entre um resumo que indicava seis canais e uma lista que apresentava nove. Esses casos ilustram como o sistema pode ajudar a contextualizar ocorrências e chamar atenção para informações que precisam ser verificadas.

Entretanto, os testes também mostraram limitações na confirmação de eventos e na interpretação dos telecomandos. Além disso, as respostas podem variar conforme o modelo de linguagem utilizado. Assim, o protótipo demonstra possibilidades de apoio à análise, mas ainda não foi avaliado sistematicamente quanto à precisão das explicações ou à melhoria da confiabilidade dos alertas.



Figura 7: Exemplo de contextualização de eventos e identificação de inconsistências pelo protótipo MCP.

4. Conclusões

Este trabalho investigou como características da telemetria e informações do contexto operacional podem contribuir para a interpretação de alertas de anomalia em missões espaciais. A análise de dados do ESA-ADB mostrou que a duração dos eventos, a quantidade de canais envolvidos e os desvios dos sensores apresentaram comportamentos diferentes entre as missões. Esses resultados indicam que nenhuma dessas características, isoladamente, foi suficiente para distinguir anomalias de eventos raros de forma consistente.

A análise dos telecomandos identificou associações temporais que podem ajudar a contextualizar os alertas, mas não permitem estabelecer relações de causa e efeito. Como contribuição complementar, foi desenvolvido um protótipo de assistente baseado em MCP, capaz de consultar informações e reunir evidências para apoiar a interpretação humana. Embora os exemplos exploratórios tenham demonstrado possibilidades de uso, ainda não é possível afirmar que o assistente melhora a confiabilidade dos alertas.

O estudo apresenta limitações relacionadas aos recortes selecionados, à anonimização dos dados e à ausência de uma avaliação sistemática do protótipo. Como trabalhos futuros, propõe-se ampliar a análise para outros canais e missões, investigar a combinação de diferentes características e avaliar a qualidade das respostas do

assistente. Assim, a pesquisa reforça que interpretar um alerta exige mais do que identificar um valor incomum: é necessário considerar as informações disponíveis sobre o funcionamento da nave.

4.1. Declaração de uso de Inteligência Artificial

Ferramentas de inteligência artificial foram utilizadas como apoio à revisão textual deste trabalho e à elaboração e ao ajuste de trechos de código Python na análise exploratória dos dados e na geração de gráficos. Também foi desenvolvido um protótipo experimental de assistente baseado em modelo de linguagem, integrado a ferramentas por meio do Model Context Protocol (MCP), para consultar e contextualizar informações do conjunto de dados ESA-ADB. O uso dessas ferramentas teve caráter auxiliar, cabendo aos autores a revisão dos códigos, a verificação dos resultados, a interpretação das análises e a responsabilidade pelo conteúdo apresentado.

5. Referências

[1] Fejjari A, Delavault A, Camilleri R, Valentino G (2025) A review of anomaly detection in spacecraft telemetry data. Appl Sci 15(10):5653. https://doi.org/10.3390/app15105653

[2] Kotowski K, Haskamp C, Andrzejewski J, Ruszczak B, Nalepa J, Lakey D, Collins P, Kolmas A, Bartesaghi M, Martinez-Heras J et al. (2024) European Space Agency benchmark for anomaly detection in satellite telemetry. arXiv:2406.17826. https://arxiv.org/abs/2406.17826

[3] Ruszczak B, Kotowski K, Evans D, Nalepa J (2025) The OPS-SAT benchmark for detecting anomalies in satellite telemetry. Sci Data 12:710. https://doi.org/10.1038/s41597-025-05035-3

[4] Hundman K, Constantinou V, Laporte C, Colwell I, Soderstrom T (2018) Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. In: Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. p. 387-395. https://arxiv.org/abs/1802.04431

[5] Wu R, Keogh E (2021) Current time series anomaly detection benchmarks are flawed and are creating the illusion of progress. IEEE Trans Knowl Data Eng. https://doi.org/10.1109/TKDE.2021.3112126

[6] Herrmann L, Bieber M, Verhagen WJC, Cosson F, Santos BF (2024) Unmasking overestimation: a re-evaluation of deep anomaly detection in spacecraft telemetry. CEAS Space J 16(2):225-237. https://doi.org/10.1007/s12567-023-00529-5

[7] Parthasarathy V, Saraygord Afshari S, Ferguson P (2025) A satellite fault detection system based on telemetry data using statistical process control and time-domain feature extraction. Adv Space Res 75(9):6863-6881. https://doi.org/10.1016/j.asr.2025.02.029

[8] Peña LG, Souza MLO (2013) Uma discussão sob o processo de verificação e validação de software crítico e seguro: definição de conceitos, limitações, normas, objetivos e técnicas aplicadas. Proc Ser Braz Soc Comput Appl Math 1(1). https://doi.org/10.5540/03.2013.001.01.0075. In portuguese.

[9] Clemens S, Arvind B, Bilel BS et al. (2026) Towards explainable anomaly detection for satellite telemetry. CEAS Space J. https://doi.org/10.1007/s12567-026-00767-3

[10] [ECSS] European Cooperation for Space Standardization (2024) ECSS-E-HB-40-02A: Machine learning handbook. Noordwijk: ESA Requirements and Standards Division. https://ecss.nl/home/ecss-e-hb-40-02a-15-november-2024/

[11] [ESA] European Space Agency (2024) ESA-ADB: ESA anomalies dataset [dataset]. Zenodo. https://doi.org/10.5281/zenodo.12528696