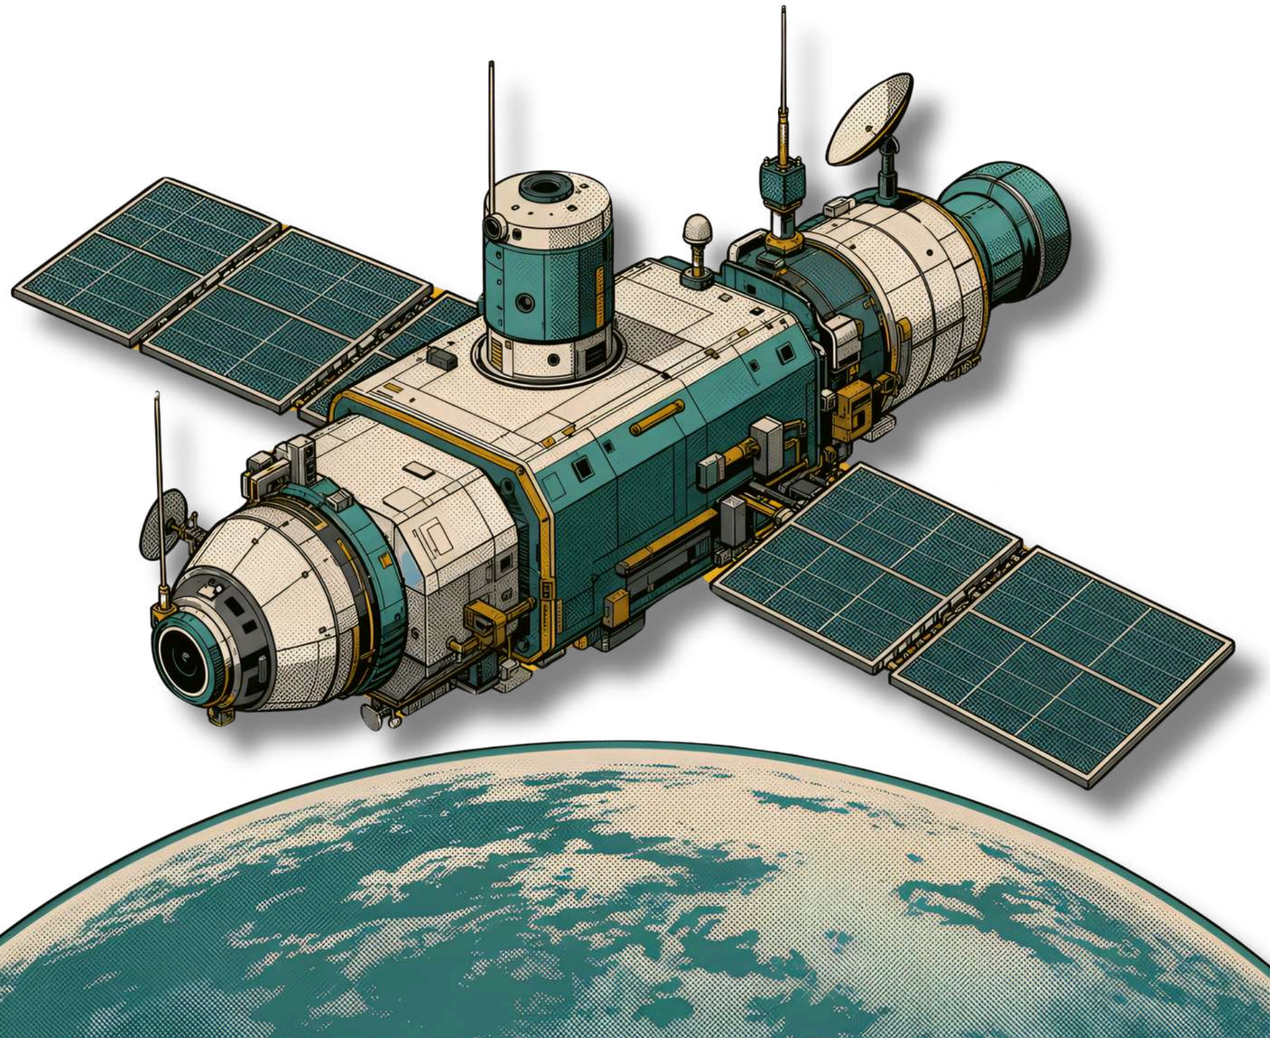
# Detecção de Anomalias em Dados de Telemetria em Naves Espaciais

**Pesquisadores:** Maria Eduarda de Lima & José João Monteiro Costa | **Orientador**: Elliot Briant

# I SIMPÓSIO DO IGM

31 DE OUTUBRO DE 2026





1. Contexto do problema e Análise de Dados

2. Desafio dos Modelos de ML

3. IA no Monitoramento e Análise de Dados

1. Contexto do Problema e Entendendo os Dados

# O que é Telemetria Espacial?

- São dados contínuos enviados para a Terra (ex: temperatura, bateria, tensão elétrica, radiação).
- Os dados não chegam à Terra em tempo real.
- **O problema operacional:** A inspeção manual por engenheiros é inviável devido à complexidade e ao volume dos dados.

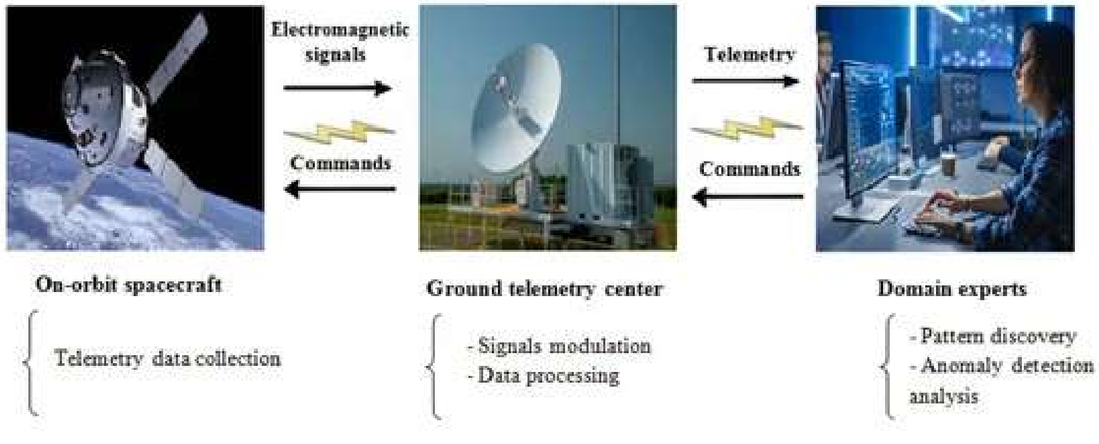



**Figura 1**: Fluxo de comunicação entre uma estação de telemetria em solo e uma espaçonave em órbita. Fonte: Fejjari et al. (2025), Appl. Sci. 15, 5653

1. Contexto do Problema e Entendendo os Dados

# Como Funciona a Detecção de Anomalias?

## Limites Fixos

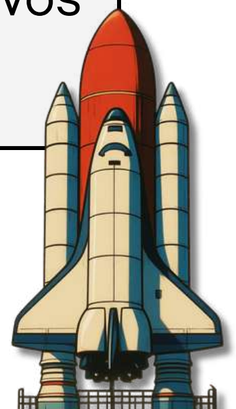
Alarme quando uma medição sai de limites predefinidos. É a técnica mais usada.

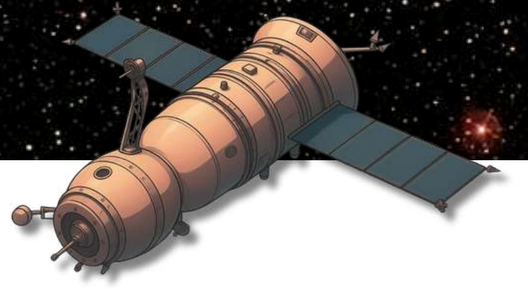
## Revisão Manual

Engenheiros inspecionam gráficos e estatísticas dos canais para achar o que os limites não pegam.

## Automação/IA

Modelos ou automações aprendem o comportamento normal, mas os falsos positivos limitam a adoção.





## 1. Contexto do Problema e Entendendo os Dados

# O que são anomalias e quais tipos existem?

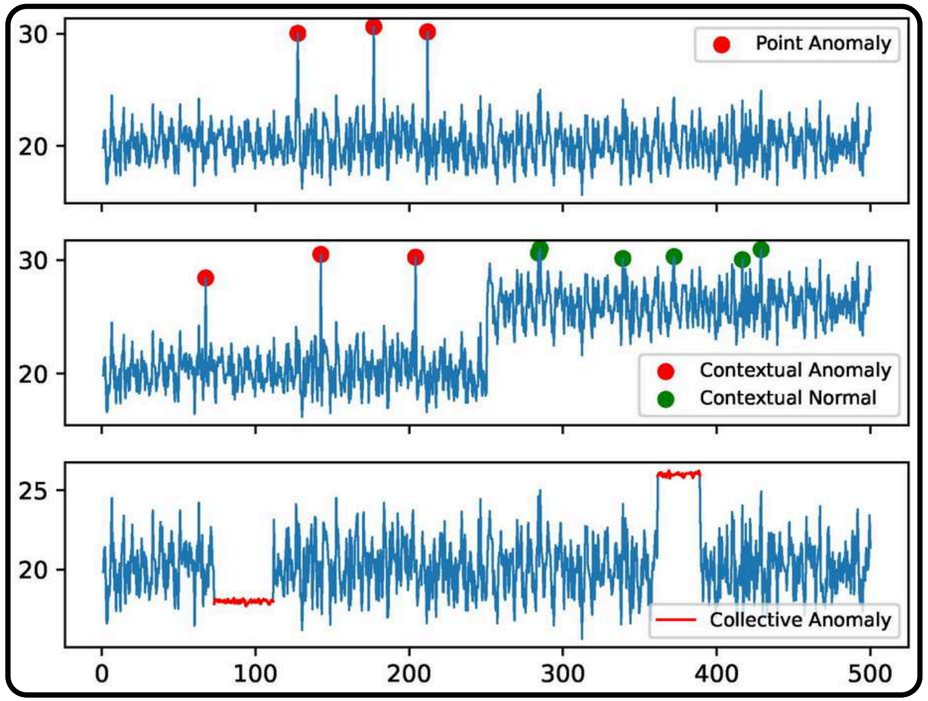



**Figura 2**:Diferença entre os tipos de anomalias em visualizações de gráficos

**Anomalia Pontual**

**Anomalia Contextual**

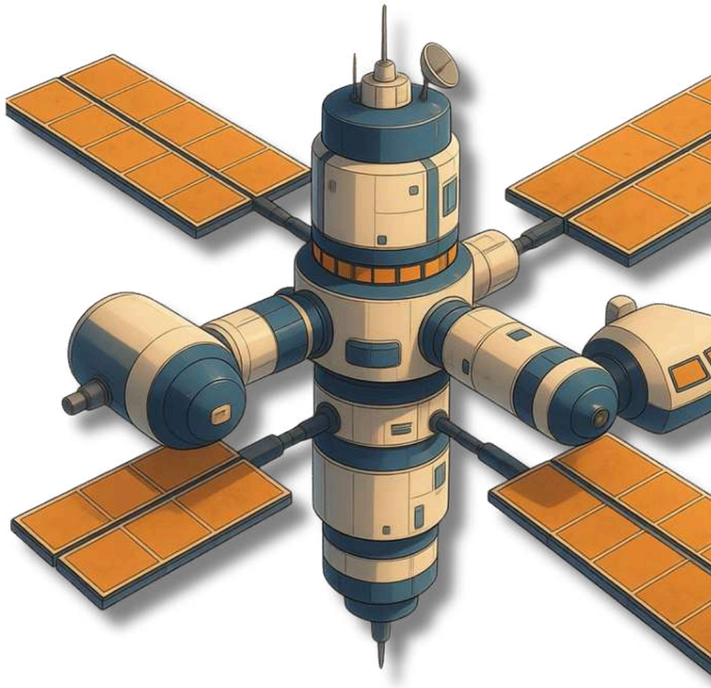
**Anomalia Coletiva**

1. Contexto do Problema e Entendendo os Dados

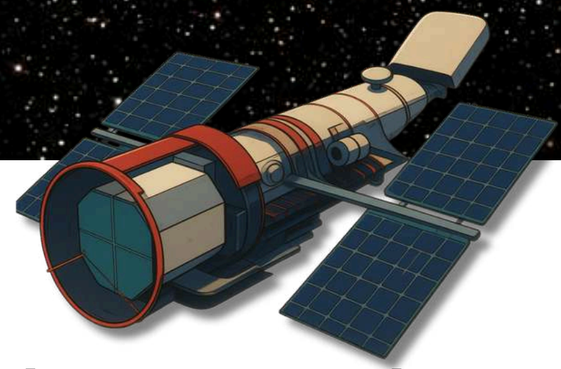
# Anomalias não é sinônimo de FALHA

- **Eventos normais parecem erros:** Manobras, ajustes e calibrações são planejados, mas fazem o sistema apitar porque o detector olha apenas para o valor isolado do sensor.

- **Falsos alarmes:** A alta taxa de avisos falsos é o maior obstáculo para usar IA nas operações.



**Quando podemos confiar nos alertas gerados por um detector?**



1. Contexto do Problema e Entendendo os Dados

# DATASET: ESA Anomaly Detection Benchmark (ESA-ADB).

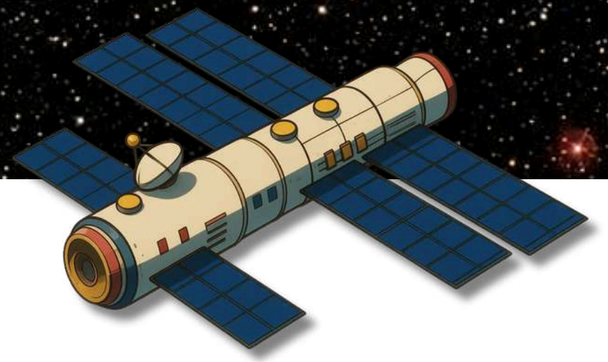
## MISSÃO 1

- 774,8 milhões de amostras registradas ao longo de 14 anos de missão (76 canais no total).
- Seleção dos Canais 41 a 46 (pertencentes ao Subsistema 5).

## MISSÃO 2

- 776,7 milhões de amostras registradas ao longo de 3,5 anos de missão (100 canais no total).
- Seleção dos Canais 18 a 28 (pertencentes ao Subsistema 1).

esa



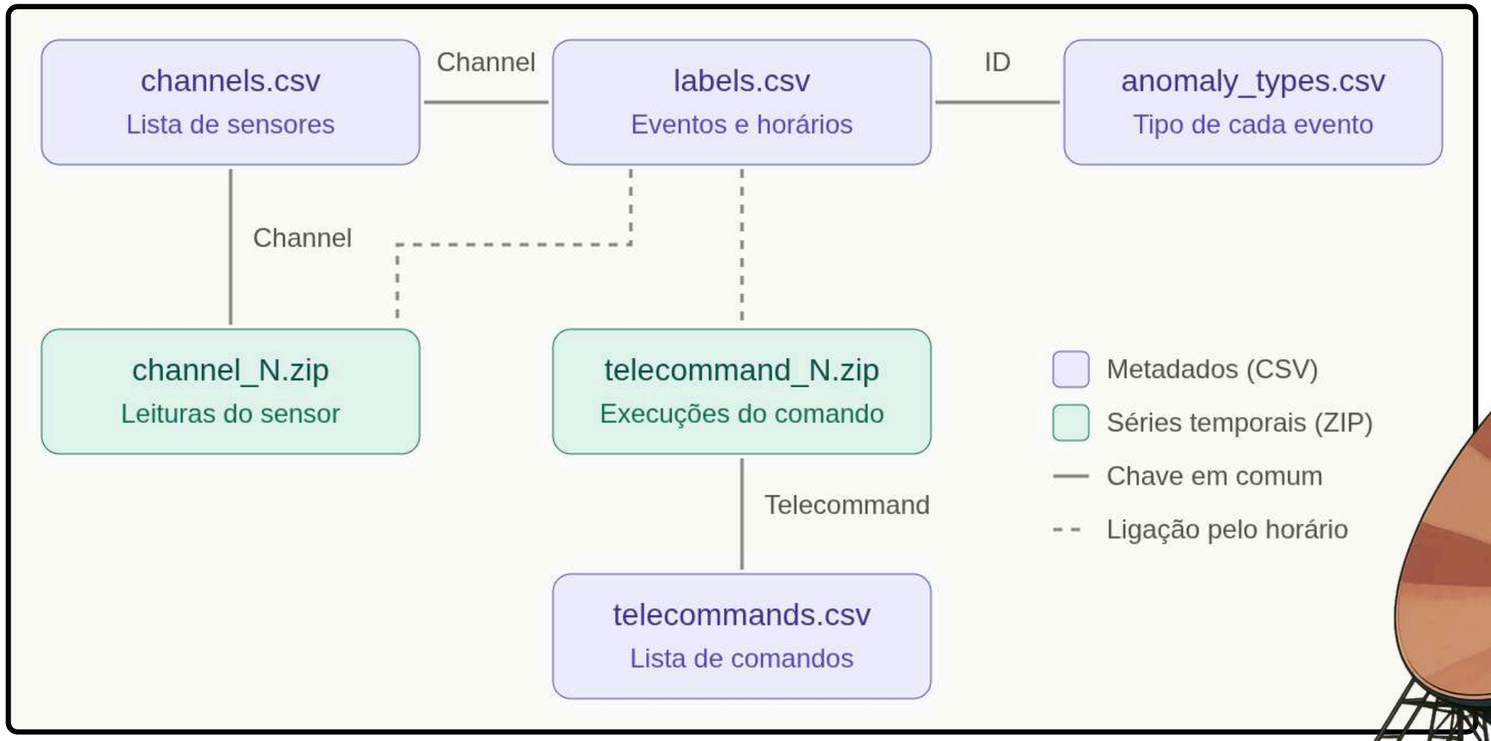
1. Contexto do Problema e Entendendo os Dados

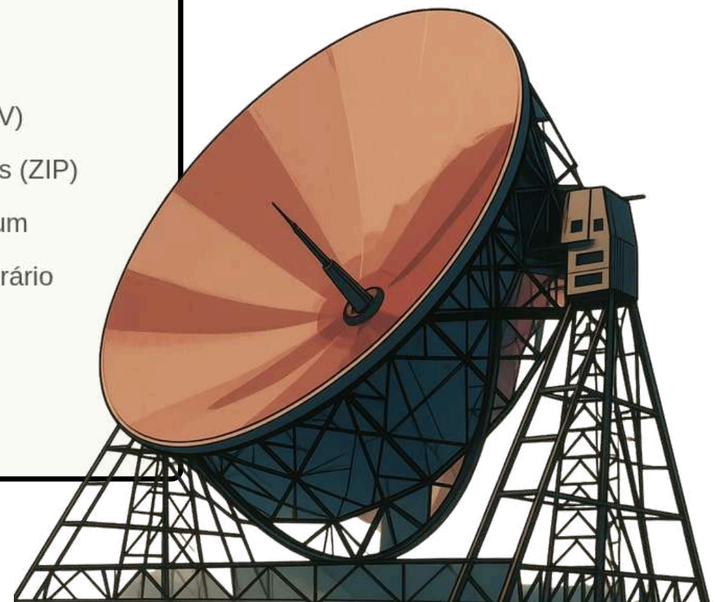
# Quais dados foram utilizados nessa pesquisa?

| Parâmetro Avaliado | Missão 1 (Canais 41–46) | Missão 2 (Canais 18–28) |
|---|---|---|
| Período | 14 anos (2000 a 2013) | 3,5 anos (2000 a 2003) |
| Leituras por Canal | 15.381.169 | 7.387.262 registros |
| Total de Eventos Únicos Catalogados | 118 eventos | 622 eventos |
| Distribuição das Classes Anotadas | 63 Raros / 51 Anomalias / 4 Gaps | 603 Raros / 19 Anomalias / 0 Gaps |

1. Contexto do Problema e Entendendo os Dados

# Estrutura dos Dados



# IMPORTANTE: Canais e Telecomandos são anônimos

=== channels_meta (canais 41–46) ===

| | Channel | Subsystem | Physical Unit | Group | Target |
|---|---|---|---|---|---|
| 40 | channel_41 | subsystem_5 | physical_unit_4 | 8 | YES |
| 41 | channel_42 | subsystem_5 | physical_unit_4 | 8 | YES |
| 42 | channel_43 | subsystem_5 | physical_unit_4 | 8 | YES |
| 43 | channel_44 | subsystem_5 | physical_unit_4 | 8 | YES |
| 44 | channel_45 | subsystem_5 | physical_unit_4 | 8 | YES |
| 45 | channel_46 | subsystem_5 | physical_unit_4 | 8 | YES |

=== labels (canais 41–46) ===

| | ID | Channel | StartTime | EndTime |
|---|---|---|---|---|
| 29 | id_1 | channel_41 | 2004-12-02T03:07:17.646Z | 2004-12-08T23:35:55.146Z |
| 30 | id_1 | channel_42 | 2004-12-02T03:07:17.646Z | 2004-12-08T23:35:55.146Z |
| 31 | id_1 | channel_43 | 2004-12-02T03:07:17.646Z | 2004-12-08T23:35:55.146Z |
| 32 | id_1 | channel_44 | 2004-12-02T03:07:17.646Z | 2004-12-08T23:35:55.146Z |
| 33 | id_1 | channel_45 | 2004-12-02T03:07:17.646Z | 2004-12-08T23:35:55.146Z |
| ... | ... | ... | ... | ... |

=== anomaly_types ===

| | ID | Class | Subclass | Category | Dimensionality | Locality | Length |
|---|---|---|---|---|---|---|---|
| 0 | id_1 | class_6 | subclass_1 | Rare Event | Multivariate | Global | Subsequence |
| 1 | id_2 | class_7 | subclass_1 | Anomaly | Multivariate | Local | Subsequence |
| 2 | id_3 | class_7 | subclass_1 | Anomaly | Multivariate | Global | Subsequence |
| 3 | id_4 | class_7 | subclass_1 | Anomaly | Multivariate | Local | Subsequence |
| 4 | id_5 | class_7 | subclass_1 | Anomaly | Multivariate | Local | Subsequence |

=== tc_meta ===

| | Telecommand | Priority |
|---|---|---|
| 0 | telecommand_1 | 1 |
| 1 | telecommand_2 | 1 |
| 2 | telecommand_3 | 1 |
| 3 | telecommand_4 | 1 |
| 4 | telecommand_5 | 1 |
| ... | ... | ... |

## 1. Contexto do Problema e Entendendo os Dados

# Duas missões, dois cenários

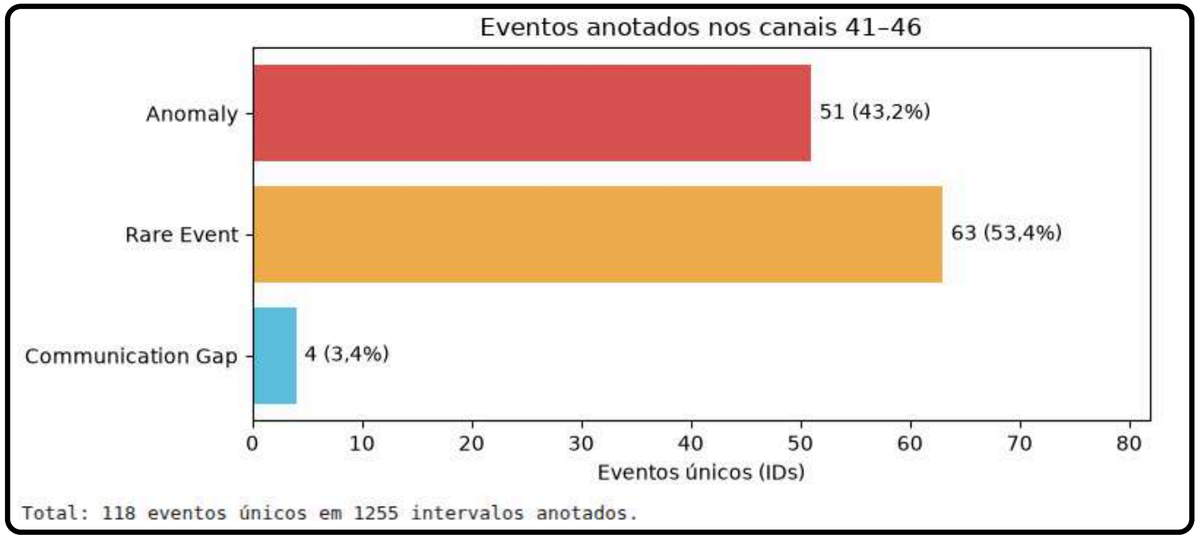



**Figura 3**: Analisando a quantidade de eventos anotados nos canais 41-46 da mission1. Fonte: Notebooks de Análise Exploratória no Github

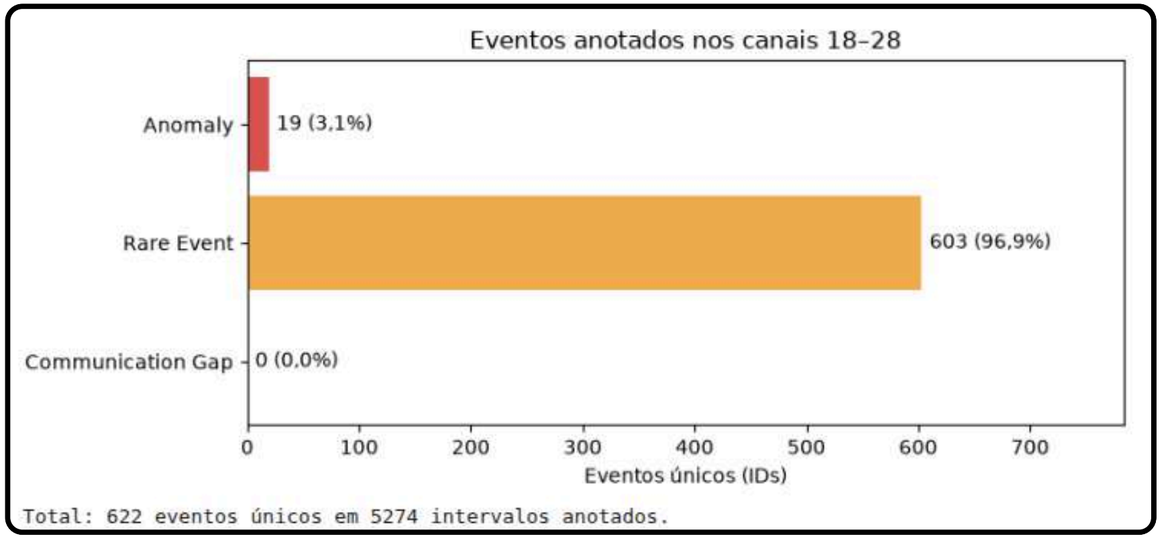
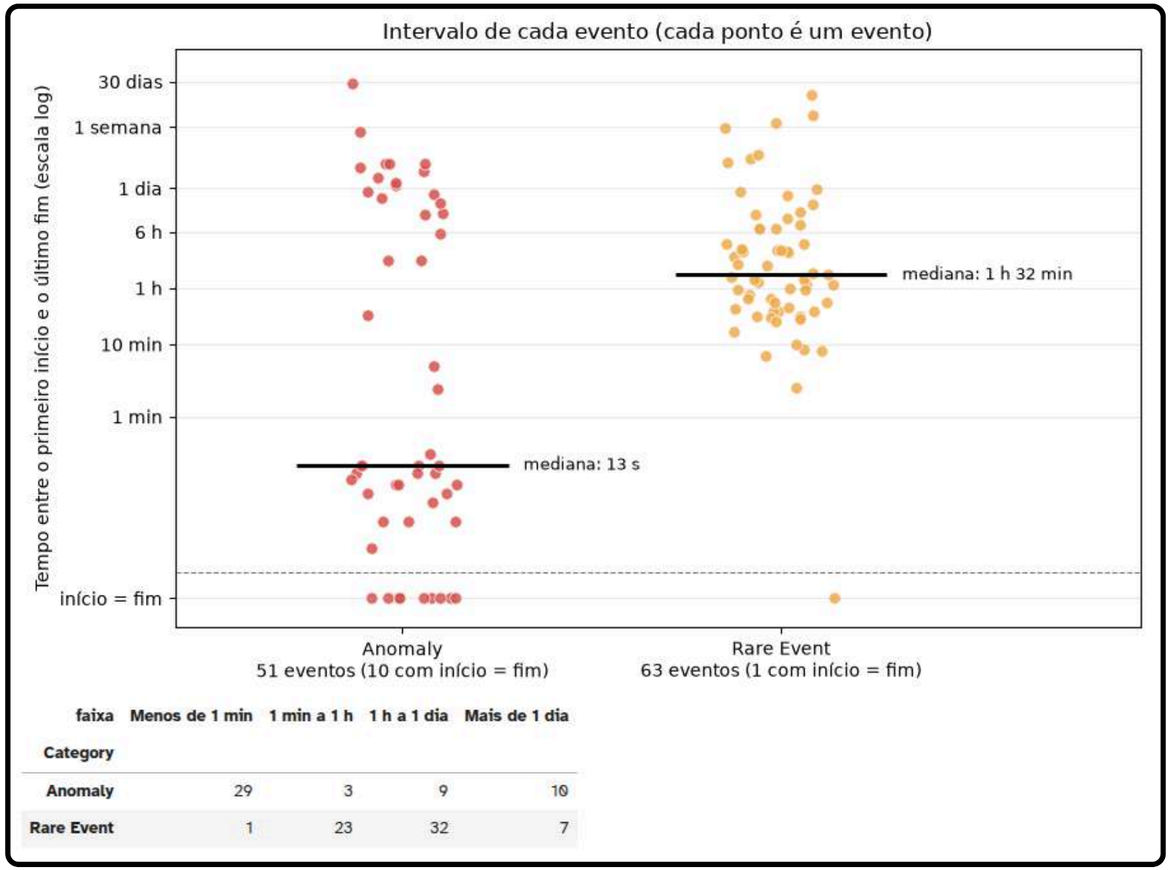



**Figura 4**: Analisando a quantidade de eventos anotados nos canais 18-28 da mission2. Fonte: Notebooks de Análise Exploratória no Github

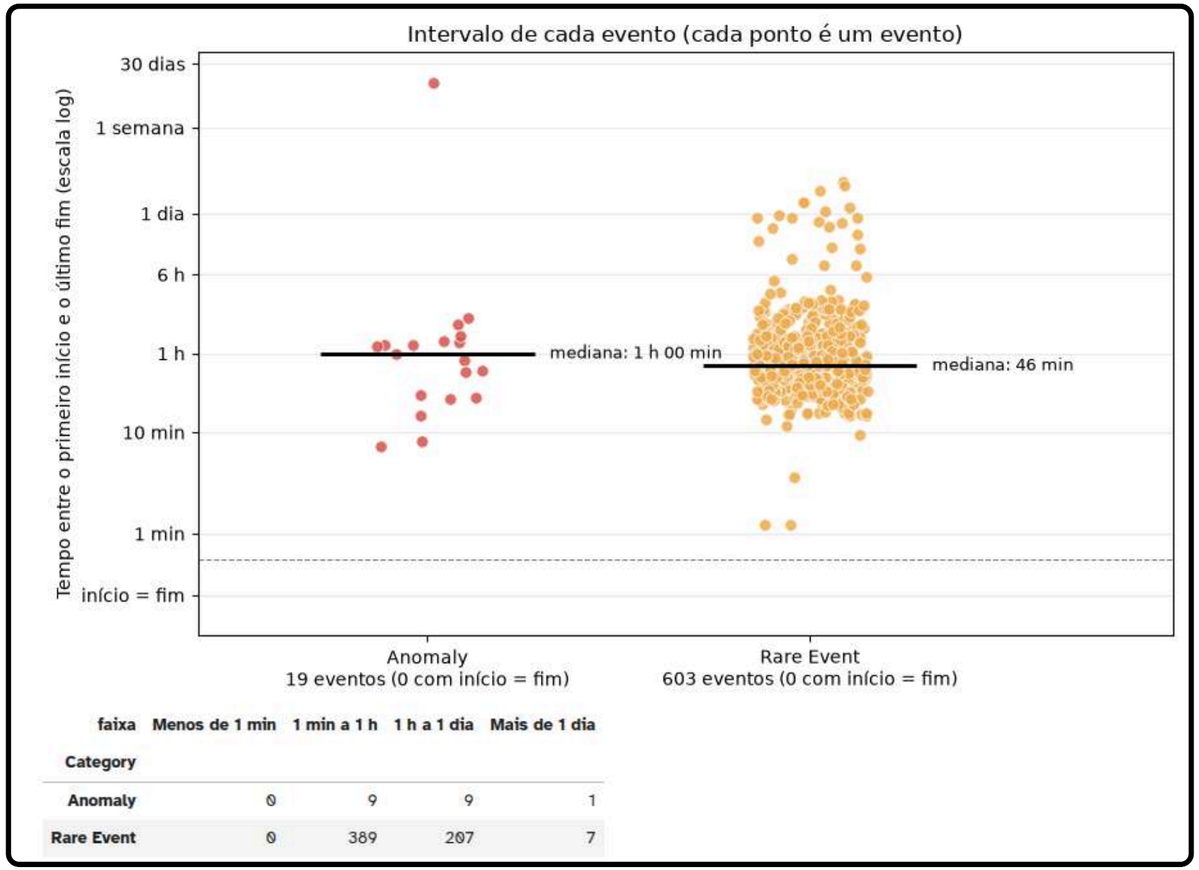
# Mission1




| faixa | Menos de 1 min | 1 min a 1 h | 1 h a 1 dia | Mais de 1 dia |
|---|---|---|---|---|
| Category | | | | |
| Anomaly | 29 | 3 | 9 | 10 |
| Rare Event | 1 | 23 | 32 | 7 |

**Figura 5**: Gráfico boxplot para visualização de tempo médio dos eventos da mission1. Fonte: Notebooks de Análise Exploratória no Github

# Mission2




| faixa | Menos de 1 min | 1 min a 1 h | 1 h a 1 dia | Mais de 1 dia |
|---|---|---|---|---|
| Category | | | | |
| Anomaly | 0 | 9 | 9 | 1 |
| Rare Event | 0 | 389 | 207 | 7 |

**Figura 6**: Gráfico boxplot para visualização de tempo médio dos eventos da mission2. Fonte: Notebooks de Análise Exploratória no Github

# Mission1

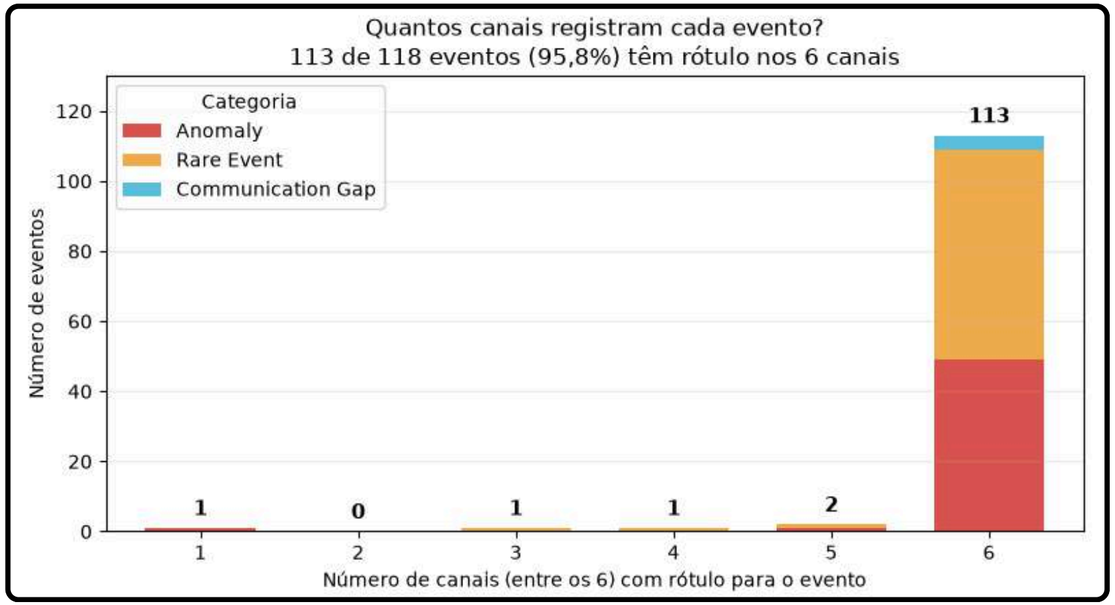



**Figura 7:** Gráfico barras para a visualização de eventos multicanais na mission1. Fonte: Notebooks de Análise Exploratória no Github

# Mission2

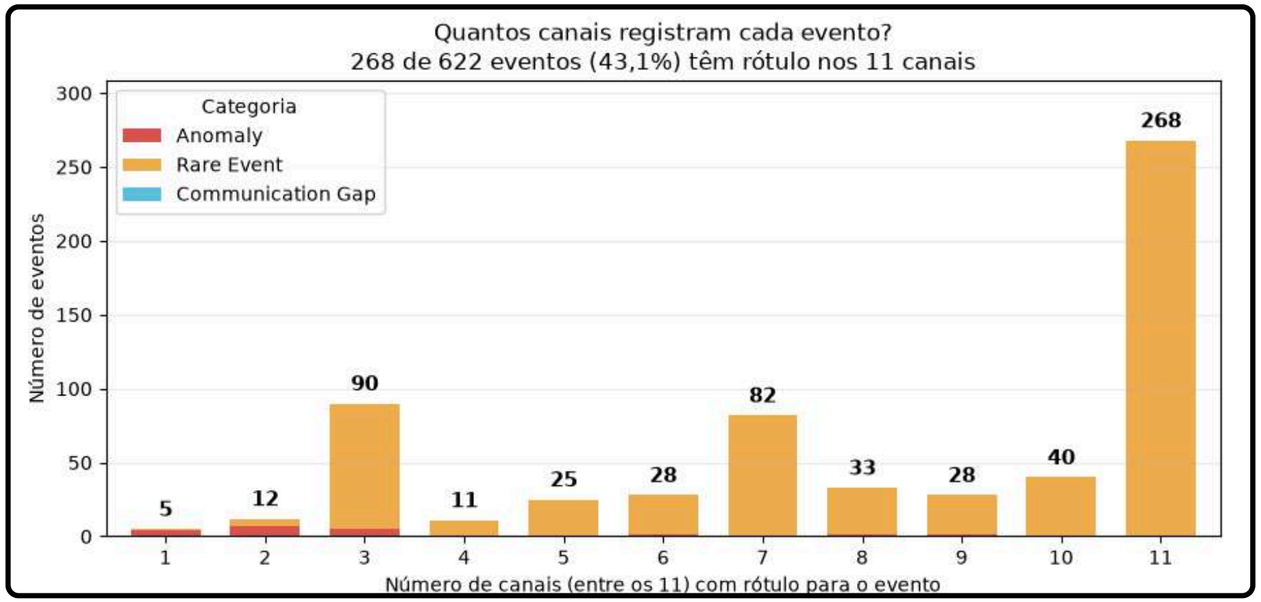



**Figura 8**: Gráfico barras para a visualização de eventos multicanais na mission2. Fonte: Notebooks de Análise Exploratória no Github

# Mission1

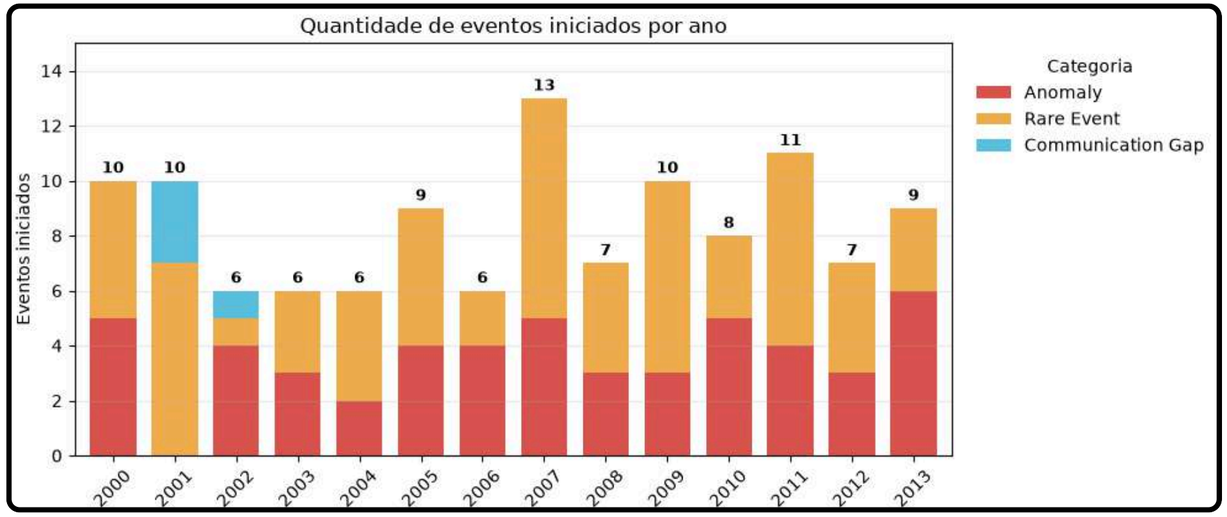



**Figura 9**: Gráfico barras para a visualização de quantidade de eventos por ano mission1. Fonte: Notebooks de Análise Exploratória no Github

# Mission2

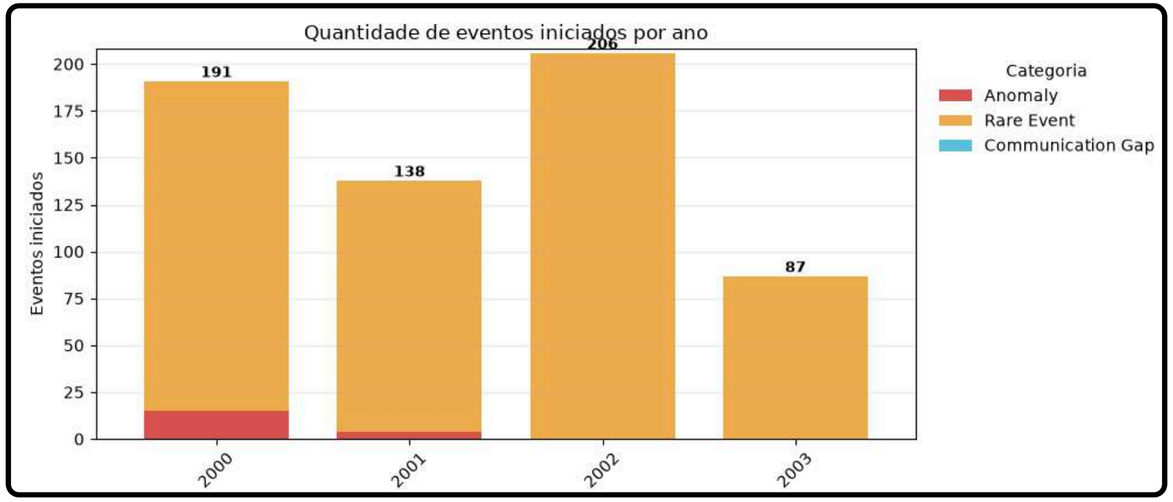
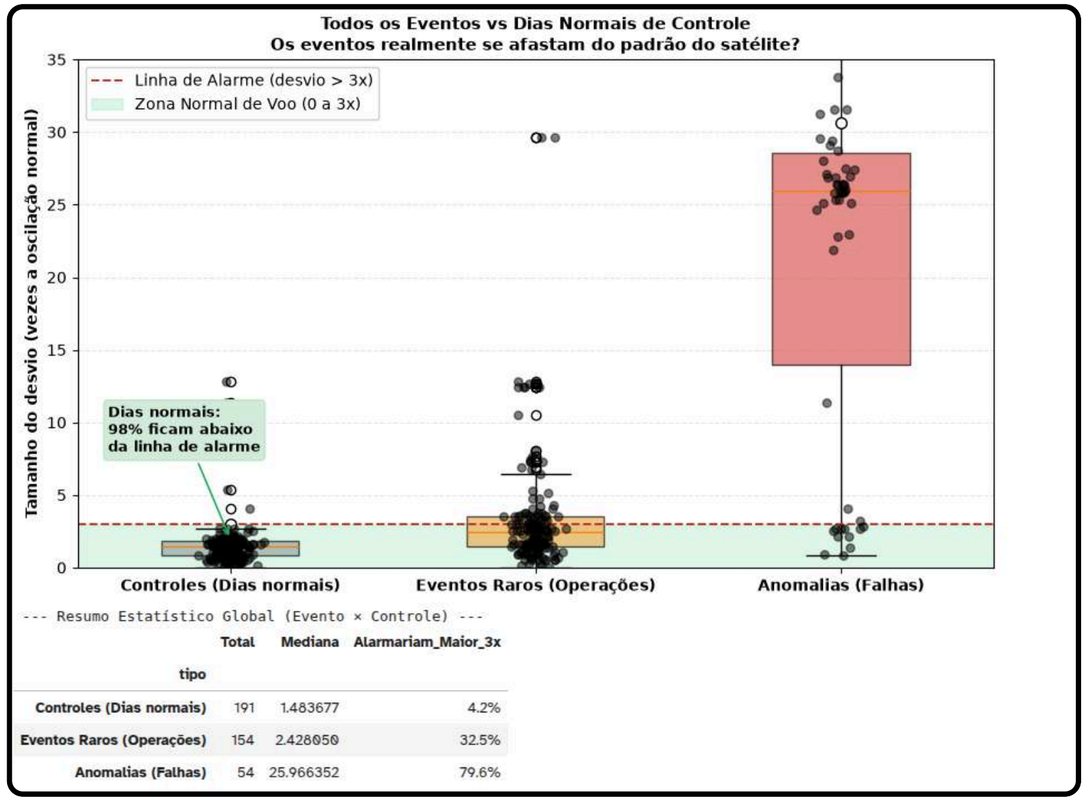



**Figura 10**: Gráfico barras para a visualização de quantidade de eventos por ano mission 2. Fonte: Notebooks de Análise Exploratória no Github

# Mission1

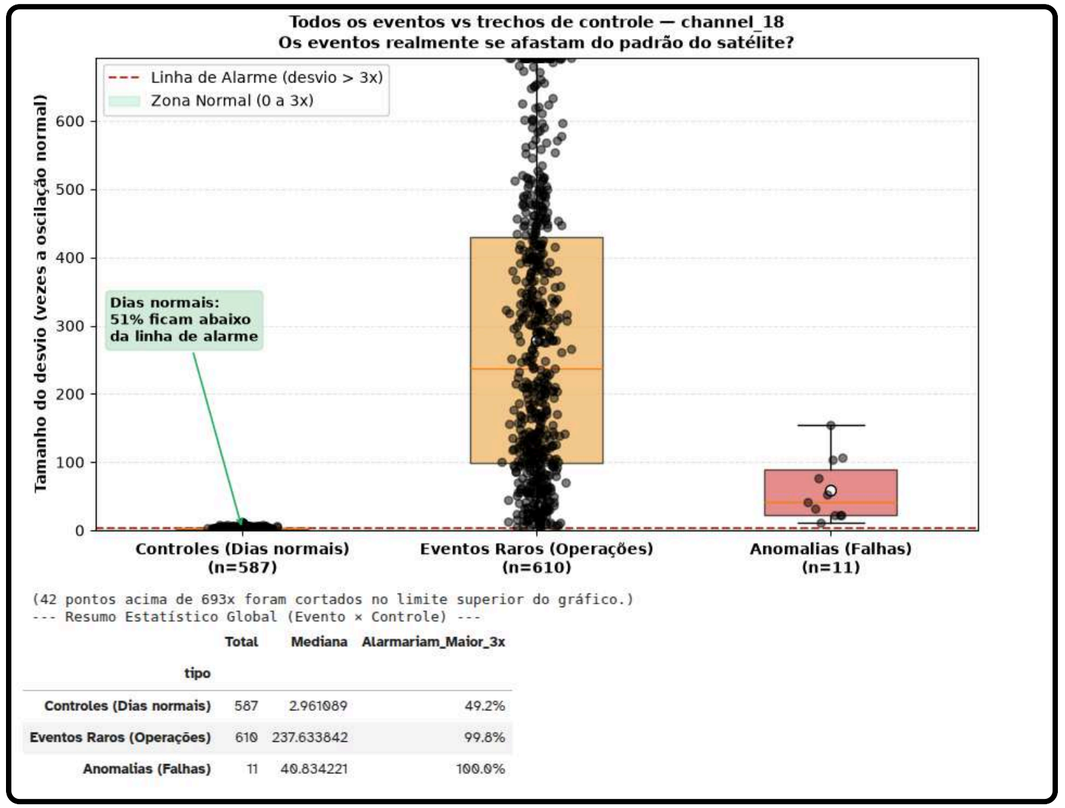



--- Resumo Estatístico Global (Evento × Controle) ---

| tipo | Total | Mediana | Alarmariam_Maior_3x |
|---|---|---|---|
| Controles (Dias normais) | 191 | 1.483677 | 4.2% |
| Eventos Raros (Operações) | 154 | 2.428050 | 32.5% |
| Anomalias (Falhas) | 54 | 25.966352 | 79.6% |

**Figura 11**: Gráfico boxplot comparando dados entre - eventos raros x dias normais x anomalias na mission1. Fonte: Notebooks de Análise Exploratória no Github

# Mission2




(42 pontos acima de 693x foram cortados no limite superior do gráfico.)
--- Resumo Estatístico Global (Evento × Controle) ---

| tipo | Total | Mediana | Alarmariam_Maior_3x |
|---|---|---|---|
| Controles (Dias normais) | 587 | 2.961089 | 49.2% |
| Eventos Raros (Operações) | 610 | 237.633842 | 99.8% |
| Anomalias (Falhas) | 11 | 40.834221 | 100.0% |

**Figura 12**: Gráfico boxplot comparando dados entre - eventos raros x dias normais x anomalias na missions. Fonte: Notebooks de Análise Exploratória no Github

# Telecomandos são acionados antes desses eventos acontecerem?

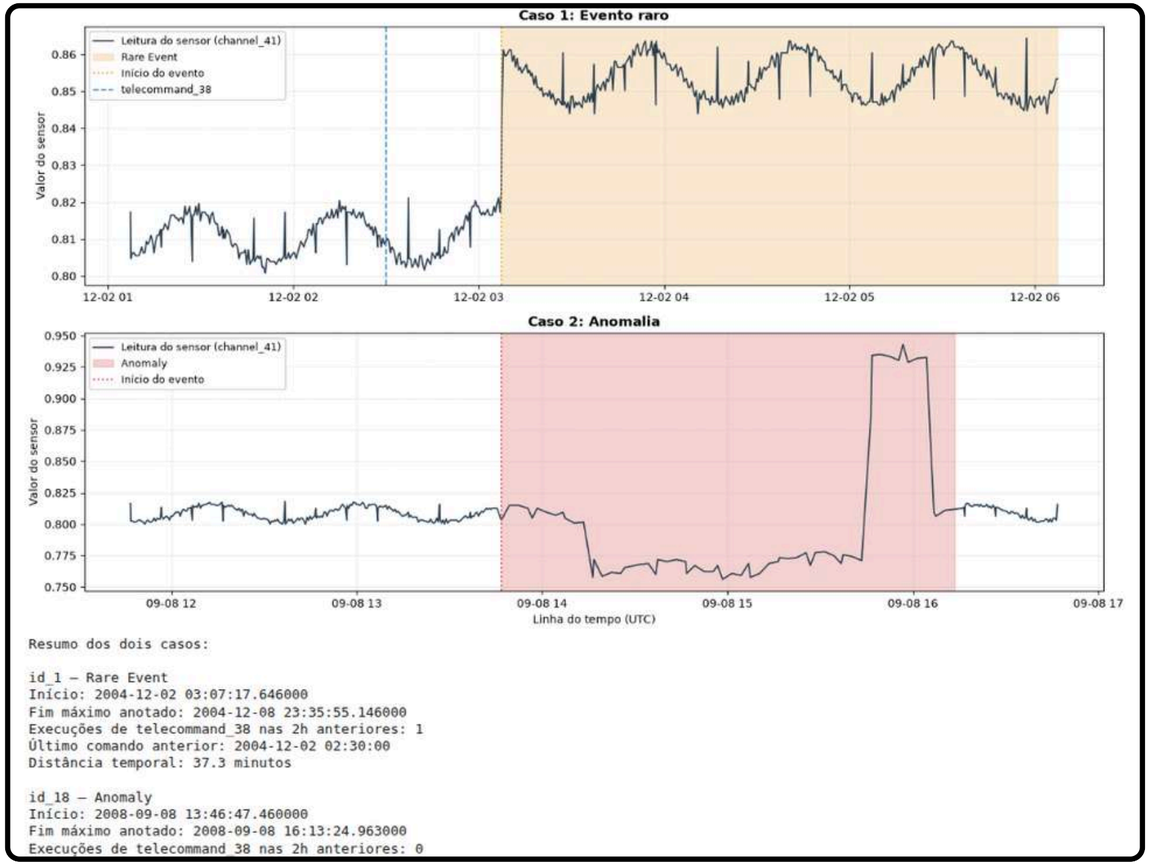



**Figura 13**: Gráfico de visualização de telecomando e eventos acontecendo logo após na mission1 . Fonte: Notebooks de Análise Exploratória no Github

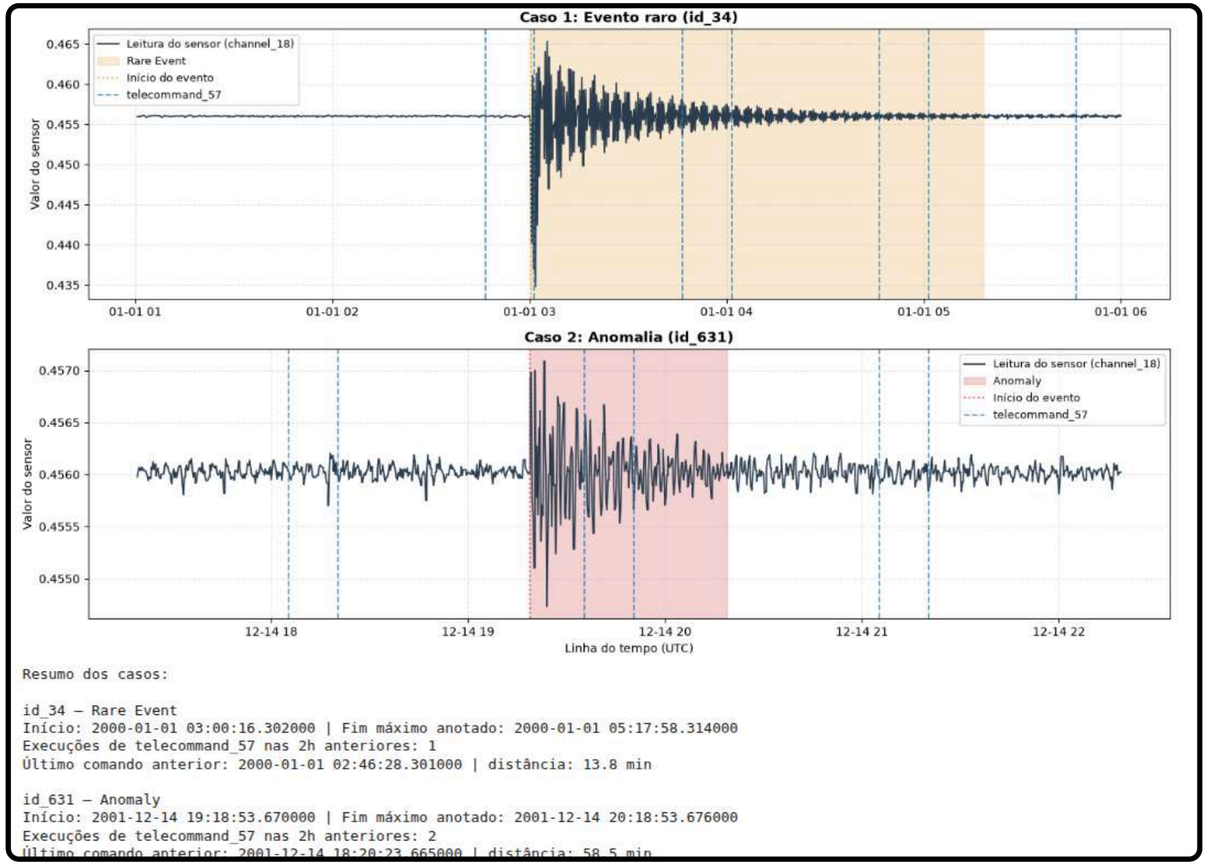



**Figura 14**: Gráfico de visualização de telecomando e eventos acontecendo logo após na mission2 . Fonte: Notebooks de Análise Exploratória no Github



2. Desafio dos Modelos de ML

# Desafios na Detecção de Anomalias

## Supervisionado

Modelos precisam de exemplos de falhas e enventos catalogados, mas as anomalias reais representam **menos de 2% dos dados operacionais.**

## Não Supervisionado

São mais indicados na detecção, pois aprendem o comportamento padrão do satélite e sinalizam qualquer desvio **sem necessitar de rótulos prévios de falhas.**

**Importante:** Algoritmos que avaliam sensores de forma univariada ou isolada são insuficientes para o setor espacial.

## 2. Desafio dos Modelos de ML

# Desempenho dos Modelos de ML

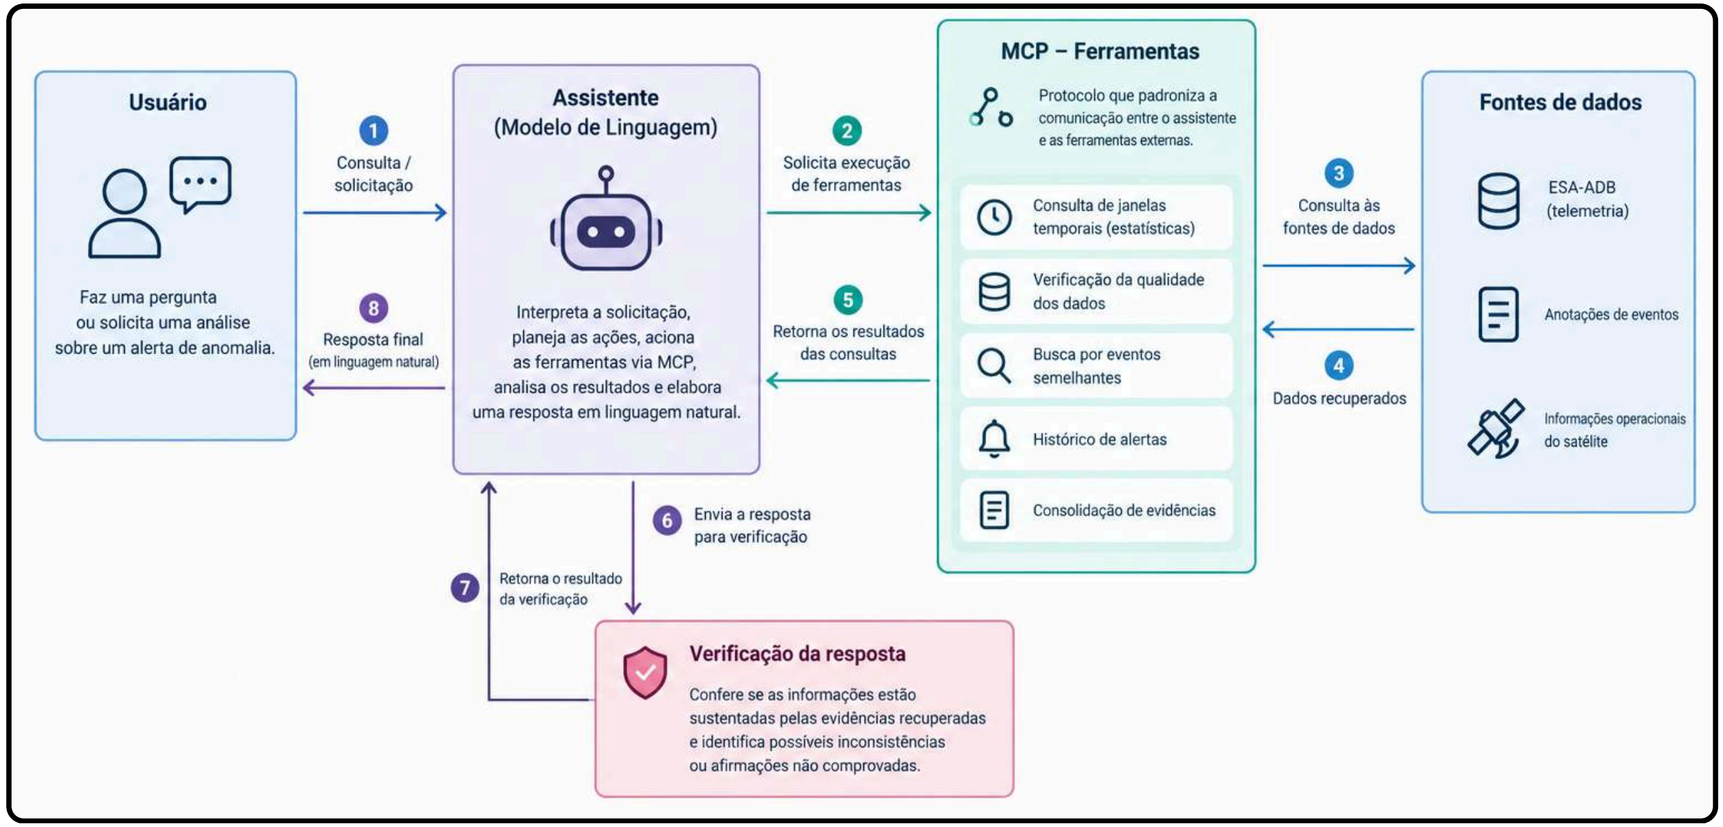
| Modelo | Como funciona | Resultados | Dificuldades |
|---|---|---|---|
| **LSTM / Telemanom**<br>Telemanom-ESA-Pruned | Prevê o comportamento esperado de cada canal e sinaliza desvios entre o valor previsto e o observado. | **NASA:** 87,5% de precisão nos alertas.<br>**Missão 1:** melhor desempenho (0,786).<br>**Missão 2:** bom desempenho (0,842), superado pelo Isolation Forest. | Sem a poda de falsos positivos, a precisão nos dados da NASA cai para 48,9%. |
| **DC-VAE**<br>DC-VAE-ESA | Aprende a reconstruir o sinal em condição normal e identifica como anômalos os trechos que não consegue reproduzir. | Boa identificação do **instante de início dos eventos**. | **Elevada taxa de falsos alarmes**, associada ao ruído nos dados: desempenho abaixo de 0,08 nas **Missões 1 e 2.** |
| **Isolation Forest**<br>Windowed iForest | Identifica pontos que se isolam do restante dos dados. | **Missão 2,** com número reduzido de canais: melhor desempenho (0,949). | **Missão 1:** desempenho muito baixo (abaixo de 0,001).<br>Não foi possível executá-lo com todos os canais simultaneamente. |

**Em comum:** nenhum dos modelos distinguiu um evento raro nominal, como uma manobra planejada, de uma anomalia.

Fonte: Hundman et al. (2018) - NASA JPL, Fejjari et al. (2025), & Kotowski et al. (2024) - ESA-ADB (arXiv:2406.17826).

### 3. IA no Monitoramento e Análise de Dados

# Copiloto para Monitoramento de Dados Espaciais




**Importante:** Qualidade da resposta depende do modelo de IA utilizado.

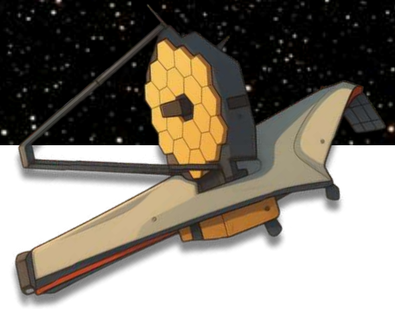





**Figura 17**: Exemplo de Resposta do MCP analisando dados da mission1 e mission2 .
Fonte: Notebooks de Análise Exploratória no Github

**Figura 18**: Exemplo de Resposta do MCP analisando dados da mission1 e mission2 .
Fonte: Notebooks de Análise Exploratória no Github



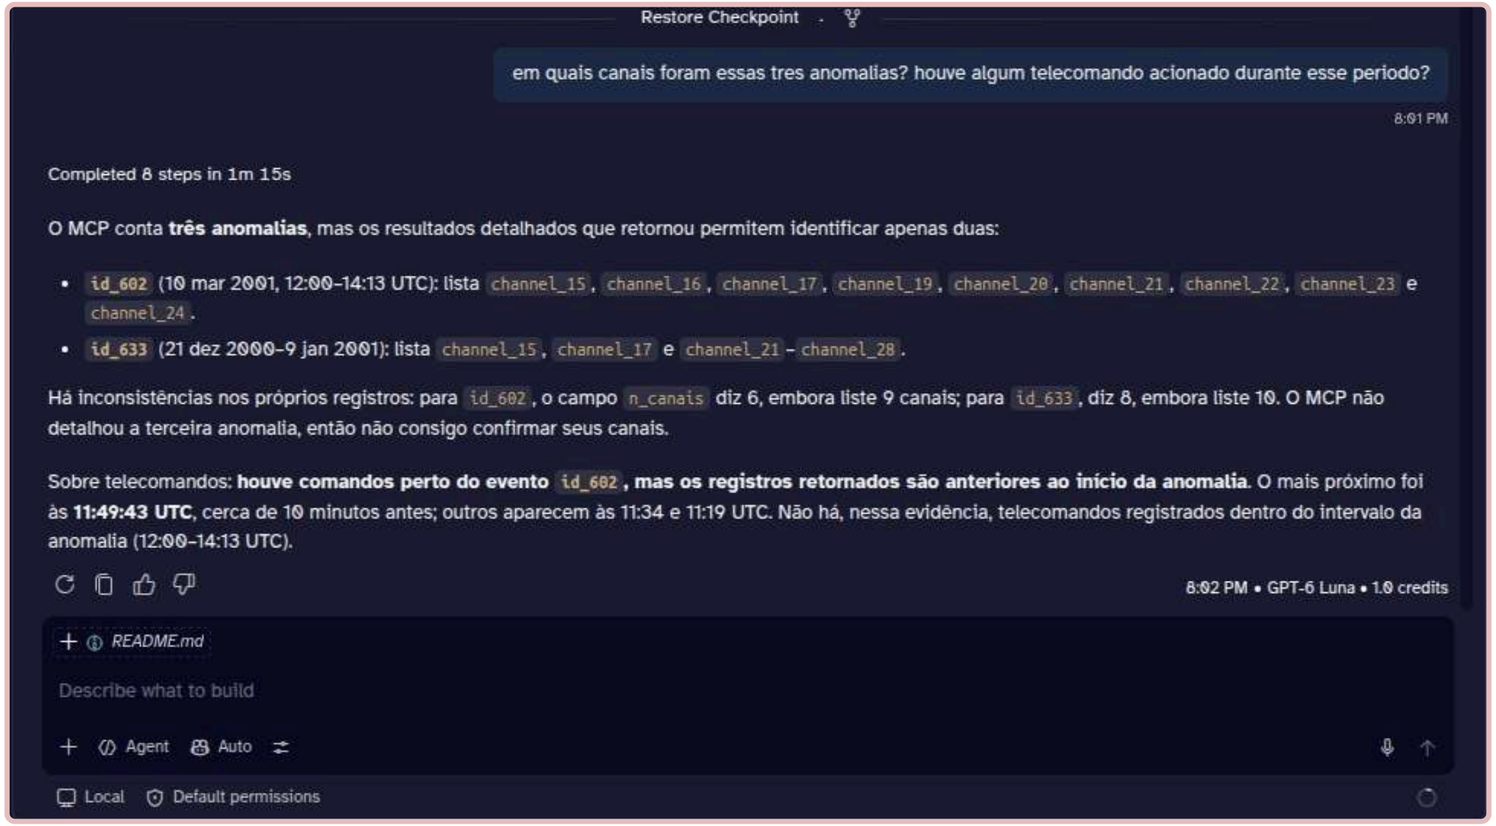
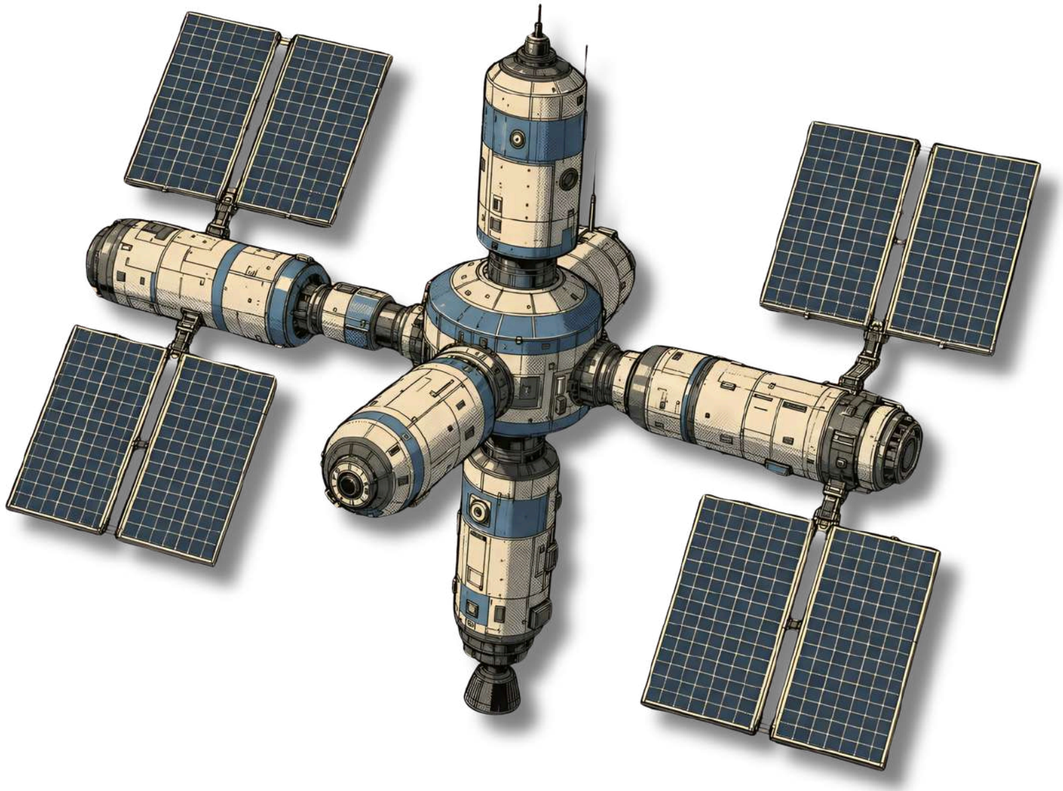



**Figura 19**: Exemplo de Resposta do MCP analisando dados da mission1 e mission2 . Fonte: Notebooks de Análise Exploratória no Github

### 3. IA no Monitoramento e Análise de Dados

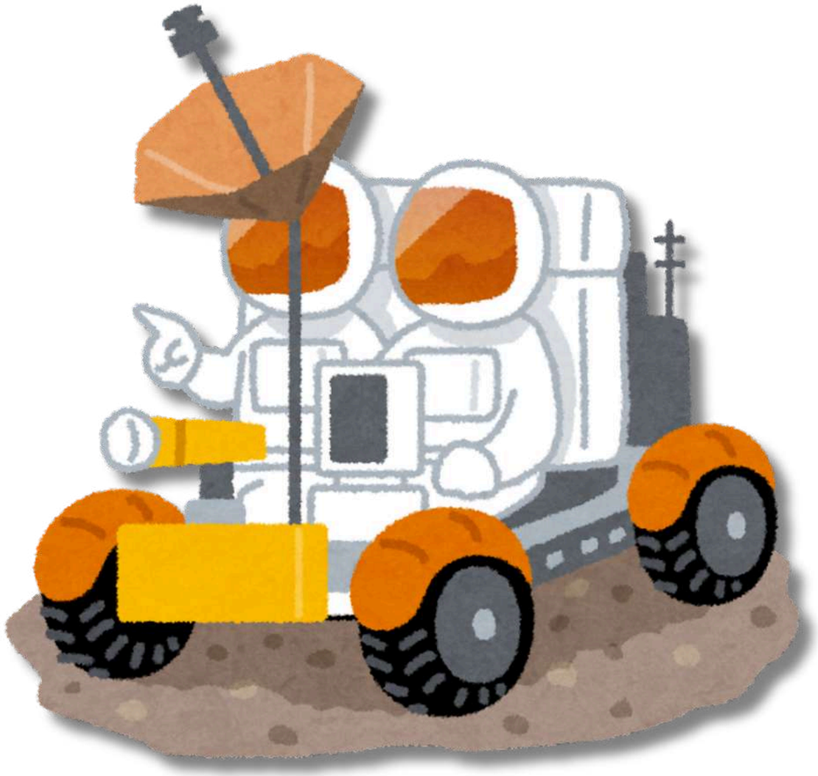
# Como o MCP poderia ajudar no monitoramento?

- Investigação Rápida e Auditada
- Integrado a dashboards
- Processamento a Bordo
- Automação de Relatórios



# Então, como garantir alertas mais confiáveis?

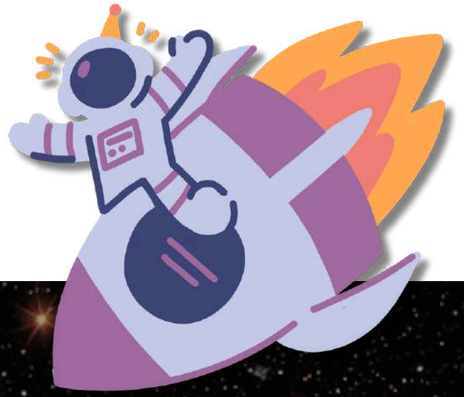
- Algoritmos de Aprendizado de Máquina Não Supervisionado Multivariada
- Integração do Contexto Operacional **(depende da base de dados fornecida)**
- **Como podemos contribuir nessa pesquisa:** criação de um copiloto com IA para auxiliar no monitoramento e análise dos dados.



# Obrigada pela atenção!

**“Sempre haverá ciência, engenharia e tecnologia. E sempre, sempre haverá matemática.” — Katherine Johnson**





**Pesquisadores:** Maria Eduarda de Lima & José João Monteiro Costa | **Orientador**: Elliot Briant